

M1 - Informatique
—
Méthodes d'optimisation

Thierry Champion

Laboratoire IMATH, Université de Toulon

bureau M141 (batiment M)
champion@univ-tln.fr

Plan du cours

On abordera les points suivants

- ▶ Résolution d'équation $F(x) = 0$
- ▶ Optimisation convexe
- ▶ Optimisation non convexe
- ▶ Optimisation sous contrainte
- ▶ Lien avec les réseaux de neurones

A propos de l'optimisation

Soit $f : E \rightarrow \mathbb{R}$ une fonction définie sur un ensemble E .

Définition

Soit K une partie non vide de E . L'élément x^* de K est un *minimiseur de f sur K* si

$$\forall x \in K, \quad f(x^*) \leq f(x).$$

A propos de l'optimisation

Soit $f : E \rightarrow \mathbb{R}$ une fonction définie sur un ensemble E .

Définition

Soit K une partie non vide de E . L'élément x^* de K est un *minimiseur de f sur K* si

$$\forall x \in K, \quad f(x^*) \leq f(x).$$

Dans ce cas on dit que *f atteint son minimum sur K au point x^** , la valeur $f(x^*)$ de ce minimum est notée

$$\min\{f(x) : x \in K\}$$

A propos de l'optimisation

Soit $f : E \rightarrow \mathbb{R}$ une fonction définie sur un ensemble E .

Définition

Soit K une partie non vide de E . L'élément x^* de K est un *minimiseur de f sur K* si

$$\forall x \in K, \quad f(x^*) \leq f(x).$$

Dans ce cas on dit que *f atteint son minimum sur K au point x^** , la valeur $f(x^*)$ de ce minimum est notée

$$\min\{f(x) : x \in K\}$$

Remarque

Si $K = E$, on parle de *minimiseur/minimum (global) de f* .

A propos de l'optimisation

Remarque

Si $K \subset E, K \neq E$, on dit que K est une contrainte du problème d'optimisation

$$\min\{f(x) : x \in K\}$$

A propos de l'optimisation

Remarque

Si $K \subset E, K \neq E$, on dit que K est une contrainte du problème d'optimisation

$$\min\{f(x) : x \in K\}$$

Définition

$x^* \in K$ est un *maximiseur de f sur K* si

$$\forall x \in K, \quad f(x^*) \geq f(x).$$

Dans ce cas on dit que *f atteint son maximum sur K au point x^** , la valeur $f(x^*)$ de ce maximum est notée

$$\max\{f(x) : x \in K\}$$

A propos de l'optimisation

Condition nécessaire d'optimalité :

Théorème (Fermat)

On suppose $E \subset \mathbb{R}^d$, x^* est un minimiseur (ou un maximiseur) de f sur K . Si x^* est un point intérieur de K et f est dérivable en x^* alors

$$\nabla f(x^*) = 0$$

Résolution d'équation $F(x) = 0$

Cas de la dimension 1

On suppose ici $E = \mathbb{R}$, et $F : \mathbb{R} \rightarrow \mathbb{R}$.

Deux familles principales de méthodes :

- ▶ Méthodes de point fixe.
- ▶ Méthode de Newton (ou Newton-Raphson)

Résolution d'équation $F(x) = 0$

Méthodes de point fixe

Soit $\omega \neq 0$ est un paramètre fixé, on réécrit alors l'équation

$$F(x) = 0$$

sous la forme équivalente

$$x + \omega F(x) = x$$

On pose $G_\omega : x \mapsto x + \omega F(x)$.

On cherche donc un point fixe de G_ω .

Résolution d'équation $F(x) = 0$

Méthode de point fixe

On fixe un point initial x^0 , et on définit $(x^n)_n$ par récurrence

$$\forall n \geq 0, \quad x^{n+1} := G_\omega(x^n) = x^n + \omega F(x^n)$$

Résolution d'équation $F(x) = 0$

Méthode de point fixe

On fixe un point initial x^0 , et on définit $(x^n)_n$ par récurrence

$$\forall n \geq 0, \quad x^{n+1} := G_\omega(x^n) = x^n + \omega F(x^n)$$

Cela donne l'algorithme :

Méthode de point fixe

- ▶ x^0 fixé, **précision $\varepsilon > 0$** fixée,
- ▶ $x \leftarrow x^0$
- ▶ tant que $|F(x)| > \varepsilon$:

$$x \leftarrow x + \omega F(x)$$

Résolution d'équation $F(x) = 0$

Critère de convergence :

Théorème (point fixe de Banach)

On suppose qu'il existe $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur K :

$$\forall x, y \in \mathbb{R}, \quad |G_\omega(x) - G_\omega(y)| \leq \kappa |x - y|.$$

Alors la suite $(x^n)_n$ générée par la méthode de point fixe à partir de x^0 converge **de manière (au moins) linéaire** :

$$\forall n \geq 0, \quad |x^{n+1} - x^*| \leq \kappa |x^n - x^*|$$

Résolution d'équation $F(x) = 0$

Critère de convergence :

Théorème (point fixe de Banach)

On suppose qu'il existe $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur K :

$$\forall x, y \in \mathbb{R}, \quad |G_\omega(x) - G_\omega(y)| \leq \kappa |x - y|.$$

Alors la suite $(x^n)_n$ générée par la méthode de point fixe à partir de x^0 converge **de manière (au moins) linéaire** :

$$\forall n \geq 0, \quad |x^{n+1} - x^*| \leq \kappa |x^n - x^*|$$

Remarque

Si x^* est une solution de $F(x^*) = 0$ telle que $F'(x^*) \neq 0$ et F' est continue en x^* , alors il existe $r > 0$ et $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur $]x^* - r, x^* + r[$.

Résolution d'équation $F(x) = 0$

Méthode de Newton (ou Newton-Raphson)

On linéarise l'équation au point initial x^0

$$F(x) \simeq F(x^0) + F'(x^0)(x - x^0)$$

Résolution d'équation $F(x) = 0$

Méthode de Newton (ou Newton-Raphson)

On linéarise l'équation au point initial x^0

$$F(x) \simeq F(x^0) + F'(x^0)(x - x^0)$$

On résoud alors l'équation

$$F(x^0) + F'(x^0)(x - x^0) = 0$$

dont la solution x^1 est

$$x^1 =$$

Résolution d'équation $F(x) = 0$

Méthode de Newton

On fixe un point initial x^0 , et on définit $(x^n)_n$ par récurrence

$$\forall n \geq 0, \quad x^{n+1} := x^n - \frac{F(x^n)}{F'(x^n)}$$

Résolution d'équation $F(x) = 0$

Méthode de Newton

On fixe un point initial x^0 , et on définit $(x^n)_n$ par récurrence

$$\forall n \geq 0, \quad x^{n+1} := x^n - \frac{F(x^n)}{F'(x^n)}$$

Cela donne l'algorithme :

Méthode de Newton

- ▶ x^0 fixé, **précision** $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^0$
- ▶ tant que $|F(x)| > \varepsilon$:

$$x \leftarrow x - \frac{F(x)}{F'(x)}$$

Résolution d'équation $F(x) = 0$

Critère de convergence :

Théorème (Convergence de la méthode de Newton)

On suppose que x^* est solution de

$$F(x^*) = 0$$

et que F est deux fois dérivable au voisinage de x^* (avec F' et F'' continues), avec $F'(x^*) \neq 0$.

Alors il existe $r > 0$ et $\beta > 0$ tels que si $x^0 \in]x^* - r, x^* + r[$, la suite $(x^n)_n$ générée par la méthode de Newton à partir de x^0 converge **de manière (au moins) quadratique** :

$$\forall n \geq 0, \quad |x^{n+1} - x^*| \leq \beta |x^n - x^*|^2$$

Résolution d'équation $F(x) = 0$

Cas de la dimension $d \geq 2$

On suppose ici $E = \mathbb{R}^d$, et $F : \mathbb{R}^d \rightarrow \mathbb{R}^d$.

Rappel : pour la partie optimisation, $F = \nabla f$

Deux familles principales de méthodes :

- ▶ Méthodes de point fixe.
- ▶ Méthode de Newton (ou Newton-Raphson)

Résolution d'équation $F(x) = 0$

pour $\omega \in \mathbb{R}^{d \times d}$ inversible

Méthode de point fixe

$$x^0 \text{ fixé; } \quad \forall n \geq 0, \quad x^{n+1} := G_\omega(x^n) = x^n + \omega F(x^n)$$

Résolution d'équation $F(x) = 0$

pour $\omega \in \mathbb{R}^{d \times d}$ inversible

Méthode de point fixe

$$x^0 \text{ fixé; } \quad \forall n \geq 0, \quad x^{n+1} := G_\omega(x^n) = x^n + \omega F(x^n)$$

Méthode de point fixe

- ▶ x^0 fixé, précision $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^0$
- ▶ tant que $|F(x)| > \varepsilon$:

$$x \leftarrow x + \omega F(x)$$

Résolution d'équation $F(x) = 0$

Critère de convergence :

Théorème (point fixe de Banach)

Si il existe $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur K :

$$\forall x, y \in K, \quad \|G_\omega(x) - G_\omega(y)\| \leq \kappa \|x - y\|.$$

Alors la suite $(x^n)_n$ générée par la méthode de point fixe à partir de x^0 converge **de manière (au moins) linéaire** :

$$\forall n \geq 0, \quad \|x^{n+1} - x^*\| \leq \kappa \|x^n - x^*\|$$

$\|\cdot\|$ est une norme sur $\mathbb{R}^d$, en général l'une des normes l^1 , l^2 ou l^∞ .

Résolution d'équation $F(x) = 0$

Remarque

Si x^* est une solution de $F(x^*) = 0$ telle que $DF(x^*)$ est inversible, et DF est continue en x^* , alors il existe $r > 0$ et $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur $B(x^*, r)$.

Résolution d'équation $F(x) = 0$

Remarque

Si x^* est une solution de $F(x^*) = 0$ telle que $DF(x^*)$ est inversible, et DF est continue en x^* , alors il existe $r > 0$ et $\kappa \in]0, 1[$ tel que G_ω est κ -contractante sur $B(x^*, r)$.

Dans ce cas, on prend pour ω une approximation de $-DF(x^*)^{-1}$

Résolution d'équation $F(x) = 0$

Méthode de Newton (ou Newton-Raphson)

On linéarise l'équation au point initial x^0

$$F(x) \simeq F(x^0) + DF(x^0).(x - x^0)$$

Résolution d'équation $F(x) = 0$

Méthode de Newton (ou Newton-Raphson)

On linéarise l'équation au point initial x^0

$$F(x) \simeq F(x^0) + DF(x^0).(x - x^0)$$

On résoud alors l'équation

$$F(x^0) + DF(x^0).(x - x^0) = 0$$

dont la solution x^1 est

$$x^1 =$$

Résolution d'équation $F(x) = 0$

Méthode de Newton

$$x^0 \text{ fixé; } \quad \forall n \geq 0, \quad x^{n+1} := x^n - DF(x^n)^{-1}.F(x^n)$$

Méthode de Newton

- ▶ x^0 fixé, **précision** $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^0$
- ▶ tant que $|F(x)| > \varepsilon$:

$$x \leftarrow x - DF(x)^{-1}.F(x)$$

Résolution d'équation $F(x) = 0$

Critère de convergence :

Théorème (Convergence de la méthode de Newton)

Soit x^* solution de $F(x^*) = 0$.

On suppose F est deux fois différentiable au voisinage de x^* (avec DF et D^2F continues), avec $DF(x^*)$ inversible.

Alors il existe $r > 0$ et $\beta > 0$ tels que si $x^0 \in B(x^*, r)$, la suite $(x^n)_n$ générée par la méthode de Newton à partir de x^0 converge de manière (au moins) quadratique :

$$\forall n \geq 0, \quad \|x^{n+1} - x^*\| \leq \beta \|x^n - x^*\|^2$$

Optimisation convexe

Rappel : condition *nécessaire* d'optimalité

Théorème (Fermat)

On suppose E de dimension finie, x^* est un minimiseur de f sur K .
Si x^* est un point intérieur de K et f est dérivable en x^* alors

$$\nabla f(x^*) = 0$$

Optimisation convexe

Rappel : condition *nécessaire* d'optimalité

Théorème (Fermat)

On suppose E de dimension finie, x^* est un minimiseur de f sur K .
Si x^* est un point intérieur de K et f est dérivable en x^* alors

$$\nabla f(x^*) = 0$$

Cette condition est aussi suffisante si f est **convexe sur K** .

Optimisation convexe

Définition

f est convexe sur *K* si

$$\forall t \in [0, 1], \quad f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y)$$

Propriétés géométriques du graphe d'une fonction convexe :

- ▶ sous ses cordes

Optimisation convexe

Définition

f est convexe sur K si

$$\forall t \in [0, 1], \quad f((1-t)x + ty) \leq (1-t)f(x) + tf(y)$$

Propriétés géométriques du graphe d'une fonction convexe :

- ▶ sous ses cordes
- ▶ au-dessus de ses tangentes (ou espaces tangents) :

si f est différentiable au point x , alors

$$\forall z \in E, \quad f(z) \geq f(x) + \langle \nabla f(x), z - x \rangle,$$

où $\langle ., . \rangle$ est un produit scalaire sur E .

Optimisation convexe

Caractérisation des fonctions convexes :

- ▶ en dimension 1, sur un intervalle $I = (a, b)$:
 - ▶ f est convexe ssi sa dérivée f' est croissante
 - ▶ f est convexe ssi sa dérivée seconde f'' est positive

Optimisation convexe

Caractérisation des fonctions convexes :

- ▶ en dimension 1, sur un intervalle $I = (a, b)$:
 - ▶ f est convexe ssi sa dérivée f' est croissante
 - ▶ f est convexe ssi sa dérivée seconde f'' est positive
- ▶ en dimension d , sur un convexe de E :
 - ▶ f est convexe ssi son gradient ∇f est monotone
$$\forall x, y \in E, \quad \langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0.$$
 - ▶ f est convexe ssi sa différentielle seconde D^2f est semi-définie positive
$$\forall v \in E, \quad \langle D^2f(x).v, v \rangle \geq 0.$$

(critère aux valeurs propres, critère de Sylvester)

Optimisation convexe - interprétation du gradient

► pour $f : \mathbb{R} \rightarrow \mathbb{R}^d$:

$f'(t)$ est un **vecteur tangent** à la courbe $(f(s))_{s \in \mathbb{R}}$ au point $f(t)$.

Optimisation convexe - interprétation du gradient

► pour $f : \mathbb{R} \rightarrow \mathbb{R}^d$:

$f'(t)$ est un **vecteur tangent** à la courbe $(f(s))_{s \in \mathbb{R}}$ au point $f(t)$.

► pour $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$\nabla f(\bar{x})$ est un **vecteur normal** à la courbe de niveau $\{x : f(x) = f(\bar{x})\}$ au point $f(\bar{x})$.

Optimisation convexe - interprétation du gradient

► pour $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$\nabla f(\bar{x})$ est un **vecteur normal** à la courbe de niveau $\{x : f(x) = f(\bar{x})\}$ au point $f(\bar{x})$.

L'équation de l'hyperplan tangent à la courbe de niveau $\{x : f(x) = f(\bar{x})\}$ au point $f(\bar{x})$ est donc :

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle = 0$$

Rappel : l'équation de l'hyperplan tangent au graphe de f au point $(\bar{x}, f(\bar{x}))$ est

$$z = f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle$$

Optimisation convexe - interprétation du gradient

► pour $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$\nabla f(\bar{x})$ est un **vecteur normal** à la courbe de niveau $\{x : f(x) = f(\bar{x})\}$ au point $f(\bar{x})$.

Rappel : formule de Taylor-Young

$$f(x) = f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle + o(\|x - \bar{x}\|)$$

donc

$\nabla f(\bar{x})$ indique la direction de plus forte croissance de f au point $\bar{x}$.

Optimisation convexe - Méthode du gradient

La méthode du gradient pour trouver une solution de

$$\min\{f(x) : x \in E\}$$

consiste à suivre le système dynamique donné par

$$\begin{cases} x(0) = x^0 \text{ fixé,} \\ \dot{x}(t) = -\nabla f(x(t)) \text{ pour } t \geq 0 \end{cases}$$

ici : $\dot{x}(t) = x'(t) = \frac{dx}{dt}(t)$

Optimisation convexe - Méthode du gradient

$$\begin{cases} x(0) = x^0 \text{ fixé,} \\ \dot{x}(t) = -\nabla f(x(t)) \text{ pour } t \geq 0 \end{cases}$$

- ▶ **méthode de descente** : $t \mapsto f(x(t))$ est décroissante sur $\mathbb{R}_+$
- ▶ cas convexe : $t \mapsto \|\nabla f(x(t))\|$ est décroissante sur $\mathbb{R}_+$
- ▶ cas convexe : $t \mapsto \|x^* - x(t)\|$ est décroissante sur $\mathbb{R}_+$
(pour tout x^* minimiseur de f)

Méthode du gradient - discrétisation

$$x(0) = x^0 \text{ fixé, } \dot{x}(t) = -\nabla f(x(t)) \text{ pour } t \geq 0$$

On discrétise évidemment ce système dynamique : pour une suite strictement croissante $(t_k)_k$ de nombres strictement positifs tendant vers $+\infty$:

$$0 = t_0 < t_1 < t_2 < \dots < t_n \rightarrow +\infty$$

on aura

$$\dot{x}(t_k) \simeq \frac{x(t_{k+1}) - x(t_k)}{t_{k+1} - t_k} \simeq -\nabla f(x^k) \text{ ou } -\nabla f(x^{k+1}) \text{ ou } \dots$$

Méthode du gradient - discrétisation

$$\dot{x}(t_k) \simeq \frac{x(t_{k+1}) - x(t_k)}{t_{k+1} - t_k} \simeq -\nabla f(x^k) \text{ ou } -\nabla f(x^{k+1}) \text{ ou } \dots$$

Pour simplifier les notations, on pose $x^k = x(t_k)$ et $\delta_k = t_{k+1} - t_k$, on obtient donc

$$\begin{cases} x^0 \text{ fixé,} \\ \forall n \geq 0, \quad x^{k+1} = x^k - \delta_n \xi_n \end{cases}$$

où $\delta_n > 0$, et ξ_n est calculé à partir des $\nabla f(x^k)$ pour $k \in \{0, \dots, \leq n+1\}$.

Méthode du gradient - discrétisation explicite

Méthode du gradient à pas constant

On fixe un point initial x^0 , et on définit $(x^n)_n$ par récurrence :

$$\forall n \geq 0, \quad x^{n+1} = x^n - \delta \nabla f(x^n)$$

où $\delta > 0$.

problème : choix de $\delta > 0 \dots$

Méthode du gradient - discrétisation explicite

Cela donne l'algorithme :

Méthode du gradient à pas constant

- ▶ x^0 fixé, $\delta > 0$ fixé, **précision** $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^0$
- ▶ tant que $|\nabla f(x)| > \varepsilon$:

$$x \leftarrow x - \delta \nabla f(x)$$

Méthode du gradient - discrétisation explicite

Théorème (Convergence de la méthode du gradient à pas constant)

On suppose

- ▶ f est **a-fortement convexe**
- ▶ ∇f est **L-Lipschitz**

alors $\min\{f(x) : x \in \mathbb{R}^d\}$ a une unique solution x^* , et la suite $(x^n)_n$ générée par la méthode du gradient à pas constant converge vers x^* pour tout choix $\delta \in \left] 0, \frac{2a}{L^2} \right[$.

Cette convergence est linéaire de taux $\sqrt{1 - 2a\delta + \delta^2 L^2}$.

Remarque : le meilleur choix théorique est $\delta = \frac{a}{L^2}$.

Méthode du gradient - discrétisation explicite

Méthode du gradient à pas optimal

On fixe un point initial $x^{(0)}$, et on définit $(x^{(n)})_n$ par récurrence :

$$\forall n \geq 0, \quad x^{(n+1)} = x^{(n)} - h_n \nabla f(x^{(n)})$$

où $h_n > 0$ est solution de

$$\min\{q_n(t) := f(x^{(n)} - t \nabla f(x^{(n)})) : t > 0\}$$

problème : calcul de $h_n \dots$

Méthode du gradient - discrétisation explicite

calcul du pas optimal

$$\min\{q_n(t) := f(x^{(n)} - t\nabla f(x^{(n)})) : t > 0\}$$

la condition nécessaire d'optimalité est

$$q'_n(t) = 0 \quad \Leftrightarrow \quad \left\langle \nabla f(x^{(n)} - t\nabla f(x^{(n)})), \nabla f(x^{(n)}) \right\rangle = 0$$

c'est une équation non linéaire $F(t) = 0$ en dimension 1 !

Méthode du gradient - discrétisation explicite

Cela donne l'algorithme :

Méthode du gradient à pas optimal

- ▶ $x^{(0)}$ fixé, **précision** $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^{(0)}$
- ▶ tant que $|\nabla f(x)| > \varepsilon$:
 - ▶ calcul de $h > 0$ optimal pour $q(t) := f(x - t\nabla f(x))$
 - ▶ $x \leftarrow x - h\nabla f(x)$

Méthode du gradient - discrétisation explicite

Méthode du gradient avec recherche linéaire

On fixe un point initial $x^{(0)}$, et on définit $(x^{(n)})_n$ par récurrence :

$$\forall n \geq 0, \quad x^{(n+1)} = x^{(n)} - h_n \nabla f(x^{(n)})$$

où $h_n > 0$ est calculé par **recherche linéaire** sur le problème

$$\min\{q_n(t) := f(x^{(n)} - t \nabla f(x^{(n)})) : t > 0\}$$

Méthode du gradient - discrétisation explicite

calcul d'un pas δ_n par recherche linéaire

on cherche une solution approchée de

$$\min\{q_n(t) := f(x^{(n)} - t\nabla f(x^{(n)})) : t > 0\}$$

- ▶ méthode d'Armijo
- ▶ méthode de Wolfe

Méthode du gradient - discrétisation explicite

calcul d'un pas δ_n par recherche linéaire

on cherche une solution approchée de

$$\min\{q_n(t) := f(x^{(n)} - t\nabla f(x^{(n)})) : t > 0\}$$

► méthode d'Armijo

On fixe $\alpha > 0$, on cherche le plus grand $h = \alpha/2^k$ (pour $k \in \mathbb{N}$) tel que :

critère d'Armijo

$$q(h) \leq q(0) + m_1 q'(0)\delta$$

où $q(t) := f(x - t\nabla f(x))$, et $0 < m_1 < 1$ est fixé.

Méthode du gradient - discrétisation explicite

calcul d'un pas δ_n par recherche linéaire

on cherche une solution approchée de

$$\min\{q_n(t) := f(x^{(n)} - t\nabla f(x^{(n)})) : t > 0\}$$

► méthode d'Armijo

- $\alpha > 0$ fixé, $0 < m_1 < 1$ fixé,
- $h \leftarrow \alpha$
- tant que $q(h) > q(0) + m_1 q'(0)h$:
 - $h \leftarrow h/2$

Méthode du gradient - discrétisation explicite

calcul d'un pas δ_n par recherche linéaire

on cherche une solution approchée de

$$\min\{q_n(t) := f(x^{(n)} - t\nabla f(x^{(n)})) : t > 0\}$$

► méthode de Wolfe

On fixe $0 < m_1 < m_2 < 1$, on cherche $h > 0$ tel que

critère d'Armijo : $q(h) \leq q(0) + m_1 q'(0)h$

critère de Wolfe : $|q'(h)| \leq m_2 |q'(0)|$

où $q(t) := f(x - t\nabla f(x))$

Méthode du gradient - discrétisation explicite

Cela donne l'algorithme :

Méthode du gradient avec recherche linéaire

- ▶ $x^{(0)}$ fixé, $0 < m_1 < 1$ et $\alpha > 0$ ou $0 < m_1 < m_2 < 1$ fixés, précision $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^{(0)}$
- ▶ tant que $|\nabla f(x)| > \varepsilon$:
 - ▶ calcul de $h > 0$ par recherche linéaire (Armijo/Wolfe) pour
 $q(t) := f(x - t\nabla f(x))$
 - ▶ $x \leftarrow x - h\nabla f(x)$

Méthode du gradient - discrétisation implicite

Méthode proximale (méthode prox)

On fixe un point initial $x^{(0)}$, et on définit $(x^{(n)})_n$ par récurrence :

$$\forall n \geq 0, \quad x^{(n+1)} = x^{(n)} - h_n \nabla f(x^{(n+1)})$$

où $\delta_n > 0$.

problème : calcul de $x^{(n+1)}$...

Méthode du gradient - discrétisation implicite

Calcul de $x^{(n+1)}$:

- résolution de l'équation non linéaire $y + h_n \nabla f(y) = x^{(n)}$

Méthode du gradient - discrétisation implicite

Calcul de $x^{(n+1)}$:

- ▶ résolution de l'équation non linéaire $y + h_n \nabla f(y) = x^{(n)}$
- ▶ réécriture de l'équation :

On remarque que si f convexe alors $x^{(n+1)}$ solution de

$$\min \left\{ f(x) + \frac{1}{2h_n} \|x - x^{(n)}\|^2 : x \in E \right\}$$

Méthode du gradient - discrétisation implicite

Calcul de $x^{(n+1)}$:

- ▶ résolution de l'équation non linéaire $y + h_n \nabla f(y) = x^{(n)}$
- ▶ réécriture de l'équation :

On remarque que si f convexe alors $x^{(n+1)}$ solution de

$$\min \left\{ f(x) + \frac{1}{2h_n} \|x - x^{(n)}\|^2 : x \in E \right\}$$

propriété : si ∇f est L -Lipschitz, alors $z \mapsto f(z) + \frac{1}{2\delta} \|z - x\|^2$ est $\frac{1}{h}$ -fortement convexe et à gradient $L + \frac{1}{h}$ -Lipschitz.

→ on peut par exemple utiliser une méthode du gradient à pas constant $\frac{h}{2}$ (si h petit).

Méthode du gradient - discrétisation implicite

Théorème (Convergence de la méthode prox)

On suppose

- ▶ f est convexe sur $\mathbb{R}^d$ (et atteint son minimum),
- ▶ il existe $h > 0$ tel que pour tout $n \geq 0$ on a $h_n \geq h$.

Alors la suite $(x^n)_n$ générée par la méthode prox converge vers un minimiseur de f .

Méthode du gradient - discrétisation implicite

Cela donne l'algorithme (pour f convexe) :

Méthode prox

- ▶ $x^{(0)}$ fixé, $h > 0$ fixé, **précision $\varepsilon > 0$** fixée,
- ▶ $x \leftarrow x^{(0)}$
- ▶ tant que $|\nabla f(x)| > \varepsilon$:
 - ▶ calcul de la solution y de

$$\min\{f(z) + \frac{1}{2h} \|z - x\|^2 : z \in E\}$$

par exemple avec la méthode du gradient à pas constant.

- ▶ $x \leftarrow y$

Optimisation convexe - Méthode de Newton

La méthode de Newton pour trouver une solution de

$$\min\{f(x) : x \in E\}$$

consiste à chercher un point critique de f par la méthode de Newton, c'est-à-dire résoudre $\nabla f(x) = 0$.

$$\begin{cases} x^{(0)} & \text{fixé,} \\ x^{(n+1)} & := x^{(n)} - D^2f(x^{(n)})^{-1} \cdot \nabla f(x^{(n)}) \end{cases}$$

problème : calcul de $D^2f(x^{(n)})^{-1} \cdot \nabla f(x^{(n)}) \dots$

Optimisation convexe - Méthode de Newton

Théorème (Convergence de la méthode de Newton)

On suppose que f admet un minimiseur local $\bar{x}$ tel que

- ▶ $D^2f(\bar{x})$ est définie positive,
- ▶ D^2f est L - Lipschitz dans un voisinage de $\bar{x}$.

Alors il existe $r > 0$ tel que, si $x^{(0)}$ est choisi dans la boule $B(\bar{x}, r)$, la suite $(x^{(n)})_n$ générée par la méthode de Newton à partir de $x^{(0)}$ converge vers $\bar{x}$. De plus :

- ▶ $x^{(n)} \rightarrow \bar{x}$ de manière quadratique,
- ▶ $\nabla f(x^{(n)}) \rightarrow 0$ de manière quadratique.

Optimisation convexe - Méthode de Newton

Cela donne l'algorithme

Méthode de Newton

- ▶ $x^{(0)}$ fixé, **précision** $\varepsilon > 0$ fixée,
- ▶ $x \leftarrow x^{(0)}$
- ▶ tant que $|\nabla f(x)| > \varepsilon$:
 - ▶ résolution de $D^2 f(x).y = \nabla f(x)$
 - ▶ $h \leftarrow 1$
 - ▶ $x \leftarrow x - hy$