

NVIDIA NVQLink

Architecture d'interconnexion pour le supercalcul hybride

L. Marandon D. Phan

Master Informatique et Mathématiques



Contrairement aux bits classiques, un qubit n'est jamais vraiment isolé de son environnement.

- **Bruit** : Interférences constantes.
- **Décohérence** : Perte de l'état quantique en microsecondes.

Conséquence : Des erreurs de calcul apparaissent presque immédiatement.

En pratique, un ordinateur quantique passe plus de temps à corriger ses erreurs qu'à calculer.

Pourquoi corriger ?

- Les erreurs quantiques arrivent très souvent
- On ne peut pas copier un qubit

Correction QEC

- **Indirecte** : on n'agit pas directement sur le qubit
- **Coûteuse** : nécessite beaucoup de calcul classique
- **Ultra-rapide** : doit se faire avant décohérence

Le QPU ne peut pas corriger ses propres erreurs seul.

Le paradoxe

- Exige un calcul classique massif
- Des milliers de mesures doivent être décodées simultanément

Impact sur le système

- La latence est le limiteur
- La QEC ne peut pas suivre

La correction d'erreurs quantiques = un problème que les GPU maîtrisent naturellement

Capacités des GPU

- Parallélisme massif
- Calculs répétitifs / vectoriels
- Latence faible et prédictible

Correspondance avec la QEC

- Calcul matriciel intensif
- Décodage de syndromes d'erreur
- Inférence rapide pour corriger les qubits

Vitesse > Précision

Une correction parfaite mais trop lente
est une correction inutile.

Connexion Classique

Le **qubit meurt** avant
l'arrivée du signal.



Objectif NVQLink

Réagir en **microsecondes**
(Temps réel).

Qu'est-ce que NVQLink ?

Une architecture d'interconnexion conçue pour unir, en temps réel, le **QPU** et le **GPU**.

Le "Système Nerveux"

Relie le corps quantique au cerveau classique (GPU).

L'Unification

Le GPU est un composant vital du QPU.

Objectif : Transformer une unité quantique isolée en un système fonctionnel.

Pourquoi NVQLink est indispensable

Boucle critique de la QEC

Mesure → Décodage → Correction

- Cette boucle doit s'exécuter **avant la décohérence**
- Une interconnexion classique est trop lente
- NVQLink ferme la boucle en temps réel

Point clé

NVQLink ne traite pas le quantique : il garantit le **temps de réaction** du système.

Boucle QEC Temps Réel (Cycle de Feedback)

QPU (Mesure des syndromes)



NVQLink : RDMA sur RoCE v2

Latence $< 4\mu\text{s}$; Débit 400 Gb/s



GPU Blackwell (Décodage BP+OSD)

Principe du RDMA

- Accès direct mémoire à mémoire
- Sans intervention CPU / OS
- Pas de copies intermédiaires

RoCE

- RDMA sur Ethernet standard
- Latence de l'ordre de la microseconde

Le syndrome est injecté directement dans le GPU, éliminant les intermédiaires logiciels.

GPU Blackwell : le "cerveau classique" du système

Décodeur ultra-rapide

Le GPU Blackwell accélère la correction d'erreurs quantiques (QEC)

- Traite des cas simultanément
- Identifie les anomalies en une fraction de seconde
- Corrige avant que l'information quantique ne disparaisse (**décohérence**)

Idée clé

Transformer un problème mathématique complexe en une opération de calcul classique instantanée

CUDA-Q : L'interface logicielle unifiée

Fusionner les flux classiques et quantiques

Le rôle de CUDA-Q

C'est la plateforme qui permet de programmer le système hybride sans gérer la complexité physique du réseau NVQLink.

- **Modèle de programmation unifié**
- **Agnosticisme matériel**
- **API temps réel**
- **Simulation accélérée**

L'avantage majeur

Le développeur se concentre sur l'algorithme : CUDA-Q gère la synchronisation et la latence du matériel.

Intégration hybride

Helios (QPU) + GPU NVIDIA GB200 NVL72 via **NVQLink** pour un décodage QEC temps réel.

- Boucle QEC : 67 μ s
- Fidélité logique : +3%
- 32× plus rapide que décohérence
- Chimie, finance, matériaux, IA
- GenQAI : accélération 234× pour données chimiques
- Workflow hybride CPU/GPU/QPU

Écosystème mondial NVQLink

Fournisseurs

Écosystème NVQLink



17 constructeurs de QPU et 9 laboratoires nationaux adoptent NVQLink

Unification du calcul classique et quantique

Unification Systémique

- NVQLink = pont entre supercalculateurs classiques et QPU
- Début de l'ère du calcul hybride Quantum-GPU

Rupture Technologique

- Latence $< 4 \mu s \rightarrow$ décodage QEC en temps réel
- GPUs Blackwell (GB200) + CUDA-Q = puissance pour rendre le QPU fonctionnel

Impact Scientifique et Industriel

- Adoption par 17 constructeurs de QPUs et 9 laboratoires nationaux
- Accélération concrète des découvertes en chimie quantique et science des matériaux

Questions ?

Merci de votre attention

GPU Blackwell : architecture et puissance

Unités de calcul

- **Tensor Cores 4^e génération** : support FP4, FP8 et INT8 pour qLDPC et algos BP-OSD
- **208 milliards de transistors** : permet le parallélisme massif et pipelines profonds
- **Throughput par GPU** : 1,3 PetaFLOPS FP16 / 2,6 PetaOPS INT8
- **FP4 optimisé** : équilibre entre précision et volume d'opérations pour la QEC temps réel

Mémoire et interconnexion

- **HBM3e** : 3,2 TB/s bande passante globale pour éviter tout goulot lors du décodage massif
- **NVLink 5** : 1,8 To/s par lien, permet multi-GPU cohérent et temps réel
- **Topologie** : maillage complet GPU GPU, NVQLink gère la cohérence mémoire
- **Accès RDMA direct** : les syndromes QPU sont injectés directement dans la VRAM GPU

Le défi algorithmique : Les codes qLDPC

Qu'est-ce que le qLDPC ?

Le **qLDPC** (*Quantum Low-Density Parity-Check*) est la méthode mathématique la plus efficace pour protéger les informations contre le bruit.

- **Complexité** : Ces codes exigent des calculs statistiques massifs (décodage sur graphes).
- **Le goulot d'étranglement** : Sur un processeur classique, ce décodage est trop lent.
- **Accélération BP+OSD** : Algorithme spécialisé exécuté par les **Tensor Cores** de NVIDIA.
- **Performance** : Gain de vitesse d'un facteur 10.

Le résultat concret

Le calcul de correction devient enfin **plus rapide** que la vitesse de disparition de l'état quantique.

Définition Mathématique

Le syndrome s est le résultat d'une mesure indirecte sur des qubits auxiliaires. Il est défini par la relation : $s = H \cdot e^T$

À quoi ça sert ?

- Détecter une anomalie sans détruire l'état quantique (superposition).
- Fournir une "carte" des erreurs au décodeur (GPU).

Où est-ce utilisé ?

- **Entrée** : Généré par le QPU.
- **Sortie** : Seule donnée transmise via NVQLink vers le GPU.

Le syndrome ne dit pas ce qu'est la donnée, il dit où elle est cassée.

Kernel Bypass :

C'est quoi ?

Technique permettant à une application d'accéder directement au matériel réseau sans passer par le noyau (Kernel) de l'OS.

À quoi ça sert ?

- **Latence** : Supprime le temps de traitement des couches TCP/IP classiques.
- **Déterminisme** : Évite les interruptions CPU imprévisibles.

Où est-ce utilisé ?

- Au cœur du protocole **RoCE v2**.
- Transfert direct : Mémoire QPU → VRAM GPU.

Le gain réel

On passe d'une latence logicielle ($> 50\mu s$) à une latence matérielle ($< 4\mu s$).

Remote Direct Memory Access (RDMA)

Définition : Transfert de données de mémoire à mémoire sans intervention du CPU ou du kernel distant.

Protocole	Couche Transport	Infrastructure
InfiniBand	Native InfiniBand	Commutateurs IB
RoCE (v1/v2)	Ethernet / UDP	Ethernet Lossless
iWARP	TCP	Ethernet Standard

